

Simulacro de Prueba de Desempeño

Programa de Formación — RIWI

Módulo:	Ingeniería de Datos — ETL, Bases de Datos y BI
Duración sugerida:	8 horas (1 jornada) o 2 sesiones de 4 horas
Modalidad:	Individual
Entregable:	Repositorio + Tablero de Power BI + Documento técnico

Contexto

Este simulacro reproduce el tipo de prueba de desempeño que evalúa competencias prácticas de análisis e ingeniería de datos. Deberás construir un pipeline de datos de extremo a extremo: desde la obtención de un dataset público hasta la entrega de un tablero de Business Intelligence que responda preguntas de negocio concretas.

Objetivo General

Diseñar e implementar un pipeline de datos completo (extracción, transformación y carga) a partir de un dataset descargado de Kaggle, persistir la información transformada en una base de datos PostgreSQL y construir un tablero interactivo en Power BI que responda cinco preguntas de negocio.

Requisitos Técnicos

- Python 3.10+ con las librerías: pandas, sqlalchemy, psycopg2 (o psycopg2-binary).
- PostgreSQL (local o en contenedor Docker) para persistir los datos transformados.
- Power BI Desktop para la construcción del tablero.
- Cuenta de Kaggle para la descarga del dataset (API o descarga manual).
- Herramienta de diagramación (draw.io, Lucidchart, Miro o similar) para el diagrama del pipeline.
- Control de versiones (Git/GitHub) para entregar el código.

Etapas de la Prueba

Etaapa 1 — Selección y descarga del dataset (Kaggle)

Ingresa a Kaggle (kaggle.com/datasets) y selecciona un dataset relacionado con un dominio de negocio de tu preferencia (ventas, e-commerce, RRHH, salud, finanzas, marketing, etc.). El dataset debe cumplir:

- Mínimo 5 columnas y 1.000 filas.
- Al menos una columna de tipo fecha/tiempo.
- Al menos una columna categórica y una numérica, para permitir agregaciones.
- Debe permitir formular preguntas de negocio relevantes (ventas, comportamiento de clientes, operaciones, etc.).

Entregable de la etapa: archivo(s) fuente descargado(s) y una breve ficha (5-10 líneas) describiendo el dataset: origen, número de filas/columnas, y por qué lo elegiste.

Etaapa 2 — Diagrama del pipeline de datos

Antes de programar, diseña un diagrama que represente el flujo completo de datos, incluyendo al menos las siguientes fases:

- Fuente (Kaggle / archivo CSV).
- Extracción (Extract) — descarga y lectura del archivo.
- Transformación (Transform) — limpieza, normalización, tipado, enriquecimiento con pandas.
- Carga (Load) — escritura en PostgreSQL.
- Consumo — conexión desde Power BI y construcción del tablero.

Entregable de la etapa: imagen o PDF del diagrama (herramienta libre), incluyendo nombres de las tablas/esquemas destino en PostgreSQL.

Etaapa 3 — Proceso ETL con pandas

Desarrolla un script (o notebook) en Python que realice como mínimo:

- Extract: carga del dataset con pandas (`read_csv` u otro).
- Transform: eliminación de duplicados, manejo de valores nulos, corrección de tipos de datos, normalización de nombres de columnas, creación de al menos 2 columnas derivadas (ej. mes, categoría de precio, antigüedad, etc.).
- Validaciones: verificación de calidad de datos post-limpieza (conteo de nulos, rangos válidos, duplicados = 0).
- Load: conexión a PostgreSQL con sqlalchemy y carga de la data transformada en una o más tablas (considera separar en un modelo simple tipo estrella si aplica: hechos y dimensiones).

Entregable de la etapa: script(s) .py o notebook .ipynb, y evidencia (captura o export) de las tablas creadas en PostgreSQL (por ejemplo, resultado de un `SELECT * LIMIT 10` y un conteo de filas).

Etapa 4 — Tablero en Power BI

Conecta Power BI directamente a la base de datos PostgreSQL (conector nativo PostgreSQL) y construye un tablero que responda las siguientes 5 preguntas de negocio (ajusta la redacción exacta al dominio del dataset elegido, manteniendo la intención de cada pregunta):

#	Pregunta	Detalle
1	Tendencia temporal	¿Cómo ha evolucionado la métrica principal (ventas, ingresos, cantidad de eventos, etc.) a lo largo del tiempo?
2	Top categorías	¿Cuáles son las 5 categorías, productos o segmentos con mejor desempeño según la métrica principal?
3	Distribución / concentración	¿Cómo se distribuye la métrica principal entre los distintos grupos (ej. regiones, clientes, canales)?
4	Comparación entre periodos	¿Cuál fue la variación porcentual de la métrica principal entre dos periodos comparables (año actual vs. año anterior)?
5	Relación entre variables	¿Existe relación entre dos variables clave del dataset (ej. precio y cantidad vendida, antigüedad y ventas)?

El tablero debe incluir al menos: 1 tarjeta (KPI) resumen, 1 gráfico de tendencia temporal, 1 gráfico de ranking/top-N, 1 gráfico de distribución y al menos 1 filtro/segmentador interactivo.

Entregable de la etapa: archivo .pbix del tablero y capturas de pantalla de cada visual respondiendo su pregunta correspondiente.

Entregables Finales

- Ficha del dataset (origen y descripción breve).
- Diagrama del pipeline de datos (imagen o PDF).
- Script(s) de ETL en Python/pandas.
- Evidencia de la carga en PostgreSQL (tablas creadas, conteo de registros).
- Archivo .pbix del tablero de Power BI con las 5 preguntas de negocio respondidas.
- Documento breve (1-2 páginas) con conclusiones e insights obtenidos.

Rúbrica de Evaluación

Criterio	Peso	Descripción
Selección del dataset y diagrama	15%	Dataset pertinente y diagrama claro del flujo E-T-L-Consumo.
Calidad del proceso ETL	30%	Limpieza correcta, validaciones, columnas derivadas útiles, código legible.
Carga en PostgreSQL	20%	Modelo de datos adecuado, tipos correctos, datos consistentes.
Tablero de Power BI	25%	Responde las 5 preguntas, visuales adecuados, interactividad, diseño claro.
Documentación y conclusiones	10%	Insights de negocio bien argumentados a partir de los datos.

Nota: Este es un simulacro de práctica creado como material de estudio y no un documento oficial de RIWI. Úsalo para ejercitar el flujo completo de un proyecto de datos antes de tu evaluación real.